

Proyecto: Sistema de reconocimiento de naipes

Objetivo

Con el fin de evidenciar lo aprendido sobre la construcción de soluciones de TinyML, se propone la creación de un sistema capaz de clasificar el palo al cual pertenece la carta As de una baraja de naipes (corazones, diamantes, picas y tréboles) mediante el uso la plataforma o SDK Edge Impulse

Se deben cumplir las siguientes tareas:

- Creación de un proyecto de Reconocimiento de Objetos.
- Consolidación y etiquetado de la base de datos de los naipes.
- Configuraciones del "Impulse" o pipeline de la solución.
- Entrenamiento y ajuste de hiperparametros del modelo neuronal.
- Evaluación de desempeño (set de datos de Test y verificación).
- Evaluación de desempeño en un dispositivo celular.



Entregable:

1. Se deben responder a las preguntas propuestas. Todo el trabajo se realiza de forma individual.

Creación del Proyecto

Para la creación del proyecto en Edge Impulse, es necesario seleccionar la opción de imágenes en el asistente de configuración que se abre inicialmente. Luego se debe seleccionar el método de detección de múltiples objetos.


 Welcome to your new Edge Impulse project! ×

You're ready to add real intelligence to your edge devices. Let's set up your project. What type of data are you dealing with?




Accelerometer data

Analyze movement of your device in real-time to predict machine failure, detect human gestures, or monitor rotating machines.




Audio

Listen to what's happening around you to create voice interfaces, listen to keywords, detect audible events, or to hear what's happening around your device.



Images

Add sight to your sensors with image classification or object detection - to detect humans and animals, monitor production lines or track objects.



Something else

Different sensor? No problem! You can collect and import data from any sensor, from environmental sensors to radars - and deploy your trained model back to virtually any device.

 Welcome to your new Edge Impulse project! ×

Great! What do you want to detect?



Classify a single object (image classification)

Detect one object in an image, for example whether you see a lamp or a plant. Image classification is efficient and can be ran on microcontrollers.



Classify multiple objects (object detection)

Detect the location of multiple objects in an image, for example to detect how many apples you see. Object detection is a lot more compute intensive than image classification and currently only works on Linux-based devices like the Raspberry Pi 4 or Jetson Nano.

Creación del Proyecto

🔔 Welcome to your new Edge Impulse project!

Great! What do you want to detect?



Classify a single object (image classification)

Detect one object in an image, for example whether you see a lamp or a plant. Image classification is efficient and can be ran on microcontrollers.



Classify multiple objects (object detection)

Detect the location of multiple objects in an image, for example to detect how many apples you see. Object detection is a lot more compute intensive than image classification and currently only works on Linux-based devices like the Raspberry Pi 4 or Jetson Nano.

Clasificar un único objeto en imágenes es un método de detección útil cuando queremos clasificar toda una imagen dentro de una categoría.

Este es un método que se puede llegar a utilizar cuando por ejemplo en el reconocimiento de los naipes, si en las imágenes de la base de datos solo va a haber una carta por imagen. Es decir, si es suficiente con que esa imagen sea un AS de picas sin saber en que parte de la imagen esta la carta.

Esta opción por el contrario permite clasificar múltiples objetos dentro de una imagen, es decir, si dentro de una misma imagen nos interesa poder distinguir diferentes objetos al igual que la ubicación de los mismos en la imagen, es necesario seleccionar esta técnica.

Debido a que nuestro interés es poder clasificar varios naipes en una imagen, procederemos a usar esta opción.

Base de Datos

Para crear la base de datos se recomiendan seguir los siguientes pasos:

- Conectar un celular a la plataforma,
- Tomar fotos de los Ases en distintas posiciones y en diferentes combinaciones, completar mínimo 80 imágenes (entrenamiento + test)
- Realizar el etiquetado de cada imagen.

Conectar el dispositivo celular

Una vez se escanea el código QR generado con una aplicación del celular (ej: Google Lens), es necesario darle permiso de acceder a la cámara para poder empezar a tomar fotos

The image shows a composite of two screenshots from the Edge Impulse platform. On the left is the main dashboard with a sidebar containing 'Dashboard', 'Devices', 'Data sources', 'Data acquisition', and 'Impulse design'. The 'Devices' section is highlighted with a blue box. An arrow points from this box to a central box labeled '+ Connect a new device'. Another arrow points from this central box to a larger box on the right titled 'Collect data'. This box contains five options for data collection: 'Connect a fully supported development board', 'Use your mobile phone' (which is highlighted with a blue border), 'Use your computer', 'Data from any device with the data forwarder', and 'Upload data'. Each option includes a brief description and a corresponding button (e.g., 'Browse dev boards', 'Show QR code', 'Collect data', 'Show docs', 'Go to the uploader').

EDGE IMPULSE

Dashboard

Devices

Data sources

Data acquisition

Impulse design

+ Connect a new device

Collect data

You can collect data from development boards, from your own devices, or by uploading an existing dataset.

- Connect a fully supported development board**
Get started with real hardware from a wide range of silicon vendors - fully supported by Edge Impulse. [Browse dev boards](#)
- Use your mobile phone**
Use your mobile phone to capture movement, audio or images, and even run your trained model locally. No app required. [Show QR code](#)
- Use your computer**
Capture audio or images from your webcam or microphone, or from an external audio device. [Collect data](#)
- Data from any device with the data forwarder**
Capture data from any device or development board over a serial connection, in 10 lines of code. [Show docs](#)
- Upload data**
Already have data? You can upload your existing datasets directly in WAV, JPG, PNG, CBOR, CSV, JSON, MP4 or AVI format. [Go to the uploader](#)

Base de Datos

Captura de imágenes

Consideraciones a tener en cuenta:




Tomar fotos con los Ases en diferentes posiciones, debido a que nos interesa poder clasificar el tipo de palo sin importar la orientación de la carta.



Incluir fotos de cada As de forma independiente, buscando hacer más robusta la base de datos.



Añadir fotos con diferentes combinaciones de cartas y tener en cuenta la distancia de la cámara con las cartas.



Tener en cuenta la cantidad de fotos tomadas por cada As y buscar que la base de datos permanezca balanceada (misma cantidad de fotos por palo).

Base de Datos

Etiquetado

Capturadas todas las imágenes de la base de datos, se procede a realizar el etiquetado de cada una de las imágenes

The screenshot displays the Edge Impulse web interface. On the left, a sidebar contains navigation links: Dashboard, Devices, Data sources, Data acquisition (highlighted with a blue box), and Impulse design. The main content area features a top navigation bar with tabs: Training data, Test data, Labeling queue (70) (highlighted with a blue box), Upload data, and Export data. Below this, there are two summary cards: 'DATA COLLECTED' showing a dash and 'TRAIN / TEST SPLIT' also showing a dash. The central part of the interface is a table titled 'Collected data' with columns: SAMPLE NAME, LABELS, ADDED, and LENGTH. The table lists six data samples, all with a label of '-' and added today at 12:50:35. The first row is highlighted in light blue. To the right of the table, there is a 'Record new data' section with a 'Connect using WebUSB' button and a message stating 'No devices connected to the remote management API.' Below this is a 'RAW DATA' section showing a sample image of four playing cards (Ace of Spades, Ace of Clubs, Queen of Spades, and King of Diamonds) with the filename 'img.jpg.2f2jk2tg.ingestion-fbbb6647-l5h5r'.

EDGE IMPULSE

- Dashboard
- Devices
- Data sources
- Data acquisition**
- Impulse design

Training data | Test data | **Labeling queue (70)** | Upload data | Export data

DATA COLLECTED: -

TRAIN / TEST SPLIT: -

Record new data [Connect using WebUSB](#)

No devices connected to the remote management API.

RAW DATA

img.jpg.2f2jk2tg.ingestion-fbbb6647-l5h5r

SAMPLE NAME	LABELS	ADDED	LENGTH
img.jpg.2f2jk2tg.ing...	-	Today, 12:50:36	-
img.jpg.2f2jkiod.ing...	-	Today, 12:50:35	-
img.jpg.2f2jh2en.ing...	-	Today, 12:50:35	-
img.jpg.2f2jkse0.ing...	-	Today, 12:50:35	-
img.jpg.2f2jhec1.ing...	-	Today, 12:50:35	-
img.jpg.2f2jfbda.ing...	-	Today, 12:50:35	-

Base de Datos

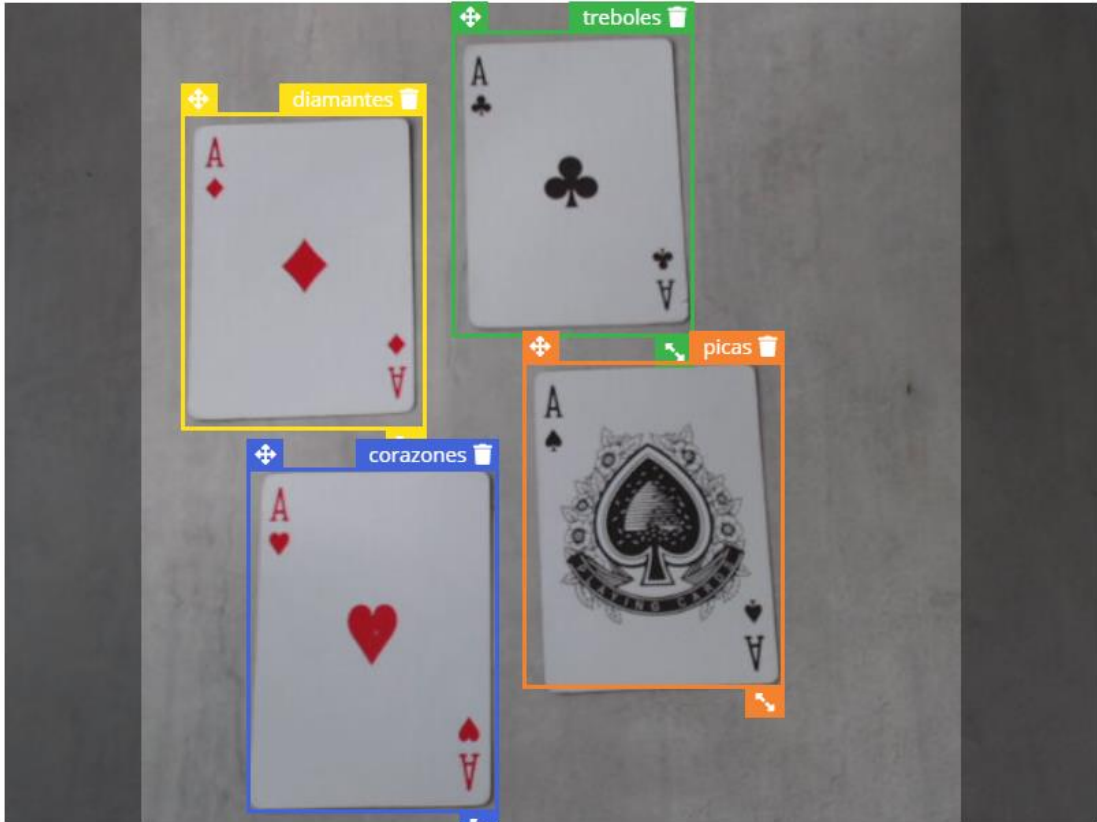
Etiquetado

Dando clic sobre la imagen construir un rectángulo que contenga cada carta de la misma imagen y etiquetarla con el nombre correspondiente, es importante que el nombre de cada etiqueta siempre sea el mismo.

Training dataTest dataLabeling queue (70)Upload dataExport data


Labeling 'img.jpg.2f2jhrdk.ingestion-fbbb6647-l5h5r' (70 items left)⚠️Label suggestions: Track objects between frames▼


Use your mouse to drag a box around an object to add a label. Then click **Save labels** to advance to the next item.



Delete sample

Una vez etiquetada, guardar los cambios y repetir el proceso hasta etiquetar todas las imágenes de la base de datos, tanto en test como en entrenamiento

DATA COLLECTED70 items

TRAIN / TEST SPLIT89% / 11% ⓘ

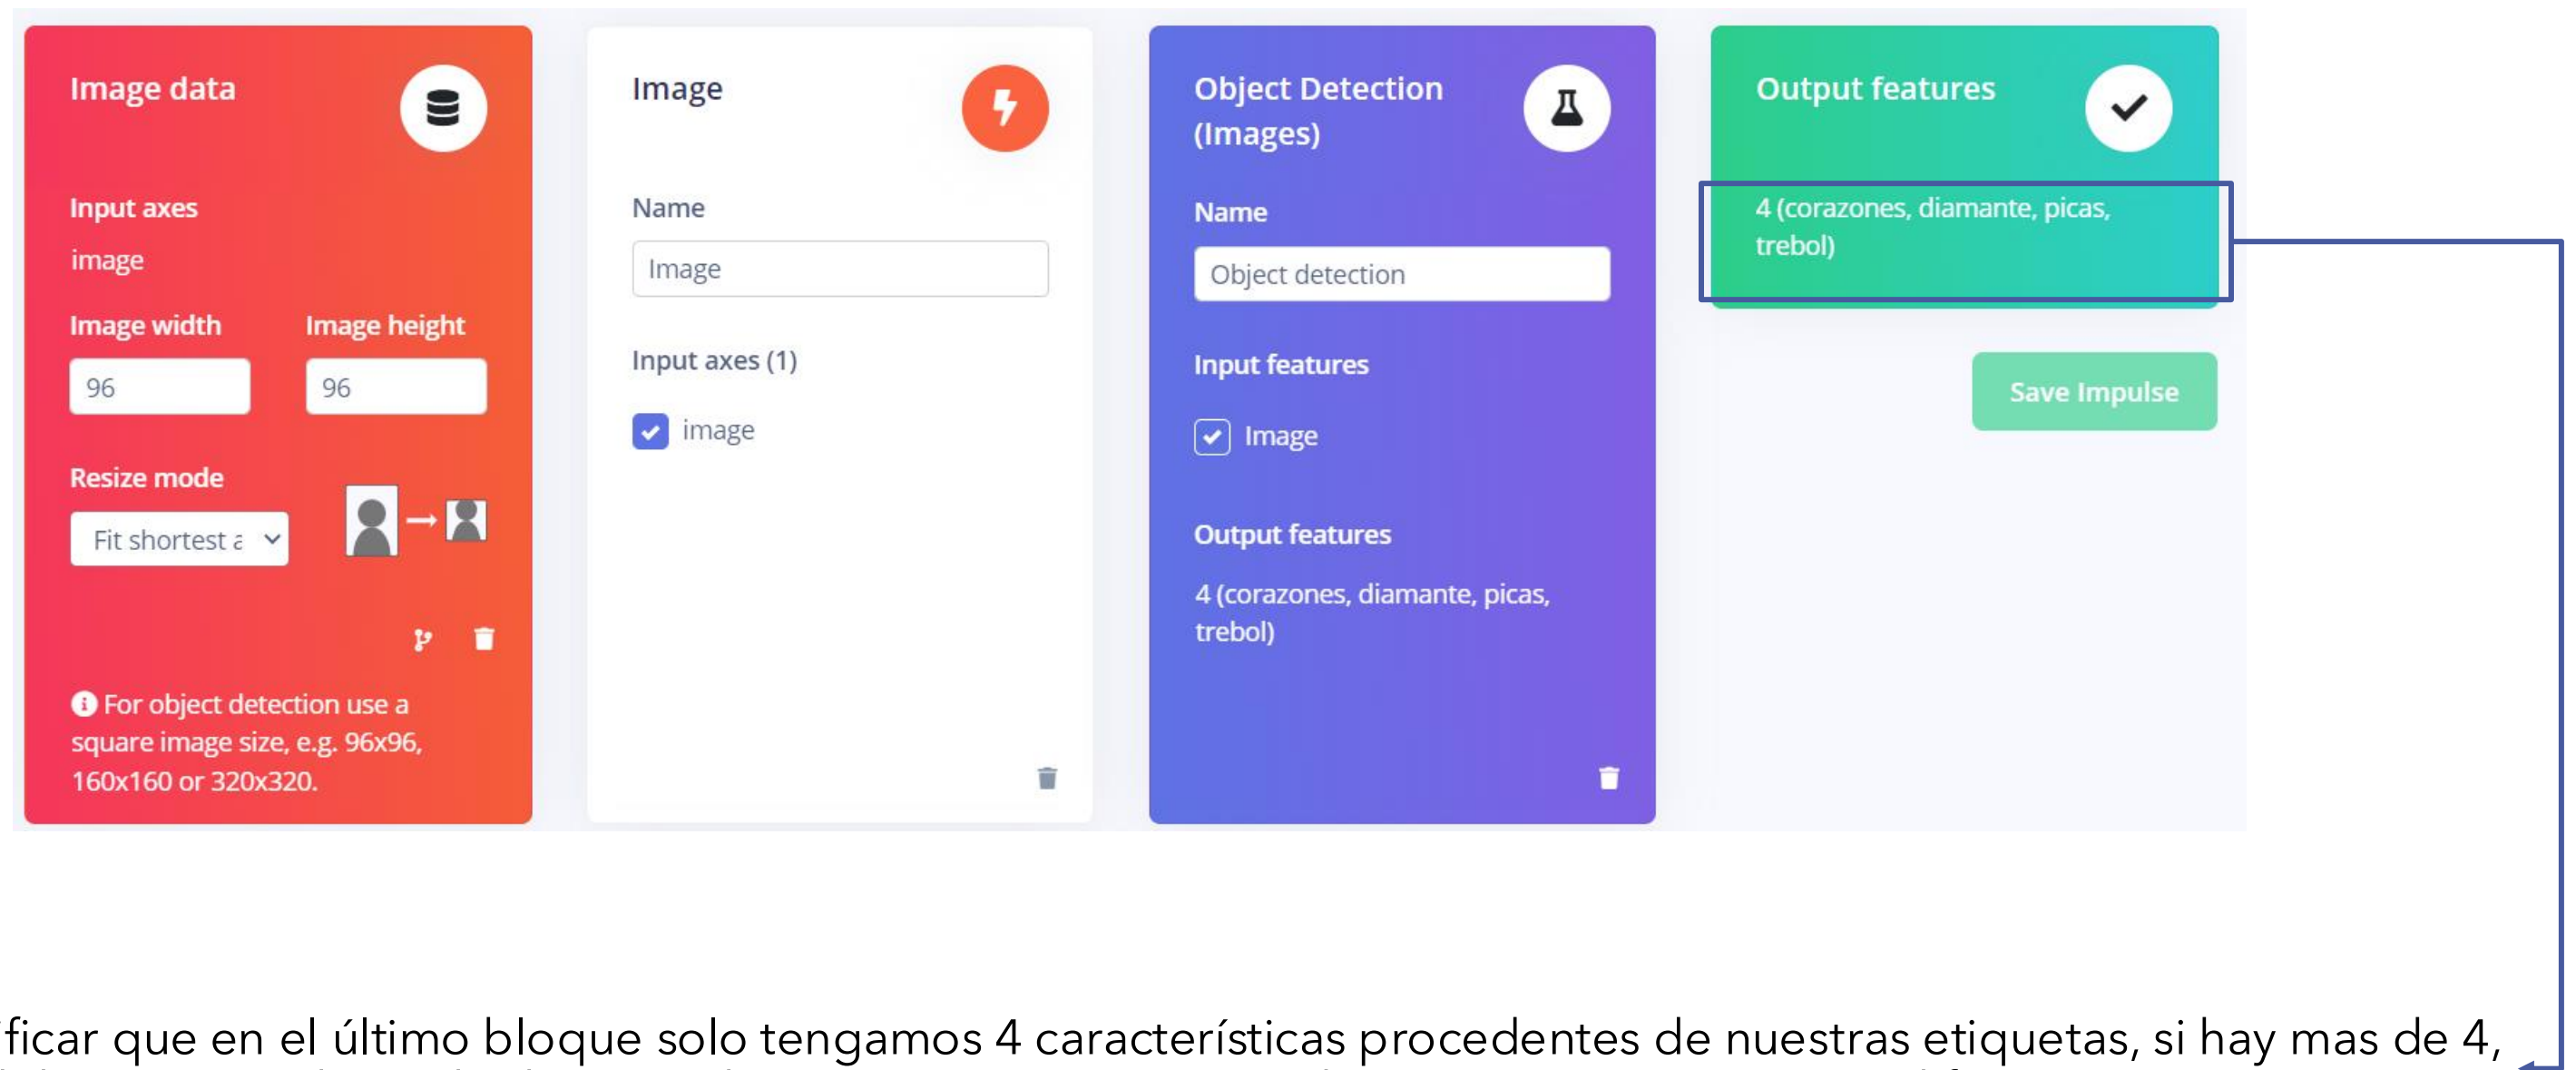
Collected data

SAMPLE NAME	LABELS	ADDED	LENGTH
img.jpg.2f2jkse0.ing...	corazones, dia...	Today, 10:32:19	-
img.jpg.2f2jlb9l.inge...	corazones, dia...	Today, 10:32:19	-
img.jpg.2f2jkiod.ing...	corazones, dia...	Today, 10:32:19	-
img.jpg.2f2jk2tg.ing...	corazones, dia...	Today, 10:32:18	-
img.jpg.2f2jjm0r.ing...	corazones, dia...	Today, 10:32:18	-

Impulse

Crear Pipeline

Definir el flujo de trabajo de la solución. Para esto se puede modificar el tamaño de la imagen con la cual se desea trabajar, seleccionar si se desea trabajar con la información original o añadir un bloque de preprocesamiento de imágenes para normalizar los valores de la imagen, y por último seleccionar el bloque de aprendizaje de detección de objetos



Verificar que en el último bloque solo tengamos 4 características procedentes de nuestras etiquetas, si hay mas de 4, se debe revisar la base de datos y editar las imágenes que quedaron con alguna etiqueta diferente.

Impulse

Preprocesamiento

En determinado caso de haber seleccionado el bloque de preprocesamiento de imágenes proceder a guardar parámetros y utilizar la opción de generar características para darnos una idea inicial y visual de que tan bien distribuidos se encuentran nuestras clases y que tan complejo puede ser el problema de clasificación que planeamos resolver.

#1

Parameters Generate features

Raw data

img.jpg.2f2jkse0.ingestion-fbbb6647-xlh

Raw features

0x908a8c, 0x918a8c, 0x8e898b, 0x8b8687, 0x8b8788, 0x8b8788, 0x8b8687, 0x888284, ...

Parameters

Image

Color depth

RGB

Save parameters

DSP result

Image

Processed features

0.5647, 0.5412, 0.5490, 0.5686, 0.5412, 0.5490, 0.5569, 0.5373, 0.5451, 0.5451, ...

Valores Originales

Valores normalizados

Parameters Generate features

Training set

Data in training set

70 items

Classes

4 (corazones, diamante, picas, trebol)

Generate features

Feature explorer

● corazones
● diamante
● picas
● trebol

On-device performance ⓘ

Explorador de características para visualizar que tan espaciados o que tan fácil puede ser diferenciar cada clase basado en los datos de entrada.

Entrenamiento

Detección de objetos

Configurar diferentes hiperparámetros y arquitecturas de modelos con el fin de evidenciar cual presenta el mejor desempeño, menor consumo energético y mayor velocidad de inferencia.

Neural Network settings

Training settings

Hiperparámetros disponibles

Number of training cycles ?

100

Learning rate ?

0.001

Validation set size ?

10


%

Data augmentation ?

☒

Neural network architecture

Input layer (27,648 features)



FOMO (Faster Objects, More Objects) MobileNetV2 0.35

Choose a different model

Output layer (4 classes)

LAYER TYPE

MobileNetV2 SSD FPN-Lite 320x320

A pre-trained object detection model designed to locate up to 10 objects within an image, outputting a bounding box for each object detected. The model is around 3.7MB in size. It supports an RGB input at 320x320px.

Add

FOMO (Faster Objects, More Objects) MobileNetV2 0.1

An object detection model based on MobileNetV2 (alpha 0.1) designed to coarsely segment an image into a grid of background vs objects of interest. These models are designed to be <100KB in size and support a grayscale input at any resolution.

Add

FOMO (Faster Objects, More Objects) MobileNetV2 0.35

An object detection model based on MobileNetV2 (alpha 0.35) designed to coarsely segment an image into a grid of background vs objects of interest. These models are designed to be <100KB in size and support a grayscale input at any resolution.

Add

Cancel

Modelos disponibles a utilizar: adicionalmente, si se desea es posible cambiar al modo experto para visualizar la red en Keras y trabajar sobre el código directamente.

Impulse

Métricas

Observar los cambios resultantes en el desempeño al cambiar la versión del modelo de una versión cuantificada y sin cuantificar.

Model

Model ver

Unoptimized (float32) ▾

Last training performance (validation set)

%

F1 SCORE

100.0%

Confusion matrix (validation set)

	BACKGROUND	CORAZONES	DIAMANTE	PICAS	TREBOL
BACKGROUND	100%	0%	0%	0%	0%
CORAZONES	0%	100%	0%	0%	0%
DIAMANTE	0%	0%	100%	0%	0%
PICAS	0%	0%	0%	100%	0%
TREBOL	0%	0%	0%	0%	100%
F1 SCORE	1.00	1.00	1.00	1.00	1.00

On-device performance ⓘ

🕒

INFERENCING ...

16 ms.

🏠

PEAK RAM USA...

898,8K

💡

FLASH USAGE

112,9K

Model

Model version: ⓘ

Quantized (int8) ▾

Last training performance (validation set)

%

F1 SCORE

90.9%

Confusion matrix (validation set)

	BACKGROUND	CORAZONES	DIAMANTE	PICAS	TREBOL
BACKGROUND	100%	0%	0%	0%	0%
CORAZONES	0%	100%	0%	0%	0%
DIAMANTE	66.7%	0%	33.3%	0%	0%
PICAS	0%	0%	0%	100%	0%
TREBOL	0%	0%	0%	0%	100%
F1 SCORE	1.00	1.00	0.50	1.00	1.00

On-device performance ⓘ

🕒

INFERENCING ...

438 ms.

🏠

PEAK RAM USA...

244,0K

💡

FLASH USAGE


78,0K

12

Evaluación de Desempeño

Captura de nuevos datos

Tomar una nueva foto con el dispositivo celular y cargarla a la plataforma con el fin de ver el desempeño del modelo con datos nunca antes vistos por el modelo.



Data collection



Connected as phone_l63r0uij

You can collect data from this device from the **Data acquisition** page in the Edge Impulse studio.

- Collecting images?
- Collecting audio?
- Collecting motion?

Classify new data

Connect using WebUSB

Device [?] phone_l63r0uij

Sensor Camera

Sample length (ms.)

Frequency Frequency selection not supported

Start sampling

Summary


Name testing.jpg.2f3inv7.ingestion-fbbb6647-xw

CATEGORY	COUNT
----------	-------

F1 score	100.00%
----------	---------

corazones	1
-----------	---

Classification result



Evaluación de Desempeño

Clasificación del set de Test

Evidenciar el desempeño del modelo con el set de datos capturado y observar que también se realiza la clasificación de cada As en las imágenes y observar en que imágenes se obtuvo una clasificación errada.

EON Tuner

Retrain model

Live classification

Model testing

Versioning

Deployment

Test data

Classify all

Set the 'expected outcome' for each sample to the desired outcome to automatically score the impulse.

SAMPLE NA...	EXPECTED OUT...	LENG...	F1 SCORE	RESULT
testing.jp...	picas	-	100%	
testing.jp...	trebol	-	100%	
testing.jp...	diamante, tre...	-	50%	
testing.jp...	corazones, pic...	-	100%	
testing.jp...	trebol	-	100%	
testing.jp...	picas, trebol	-	100%	
testing.jp...	corazones, dia...	-	75%	

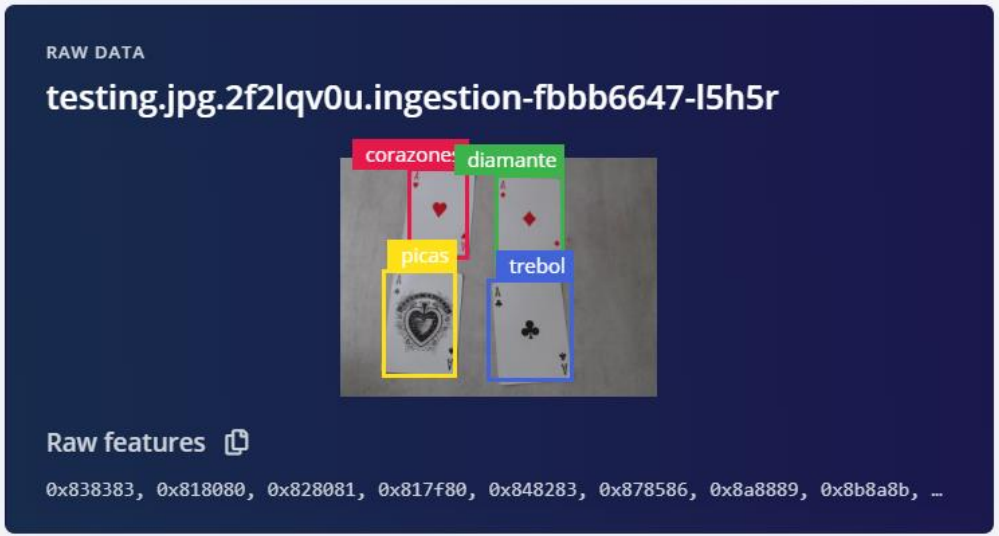
Show classification

Show in data acquisition

Move to training set

Rename

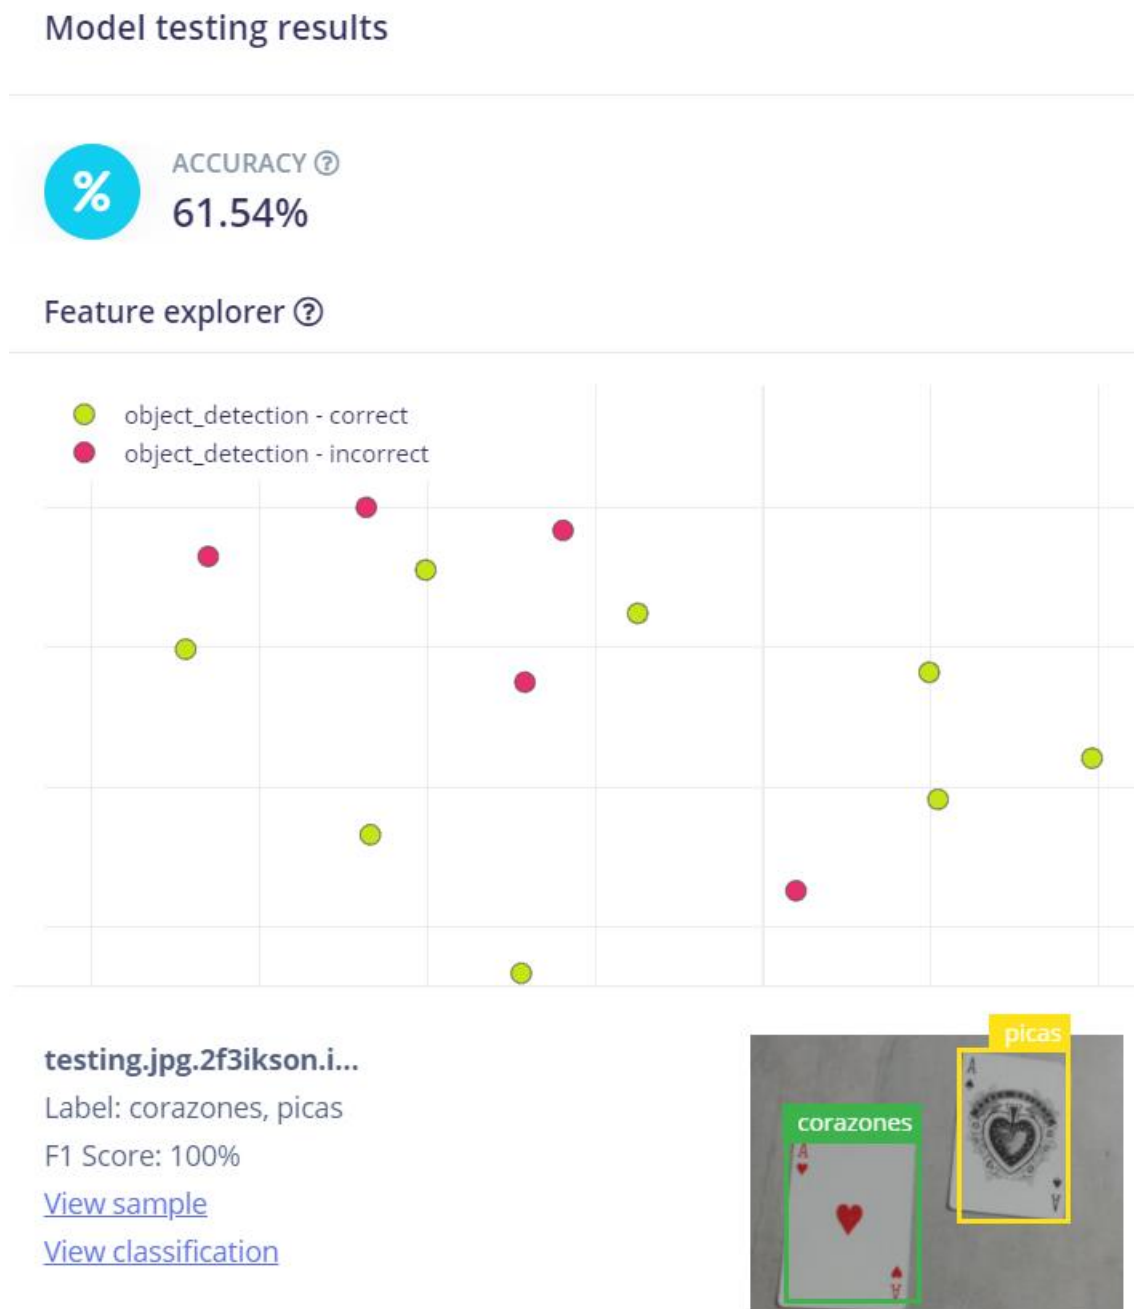
Delete



Classification result



Análisis



Análisis y preguntas a resolver

Basado en el proyecto construido realice diferentes iteraciones, modificando parámetros como, por ejemplo: base de datos, las etapas del pipeline, los hiperparámetros del modelo y responda las siguientes preguntas:

1. Mencione 3 formas en las cuales se puede mejorar el desempeño obtenido y explique por qué.
2. De las pruebas realizadas ¿Cuál fue el modelo y los hiperparámetros que obtuvieron el mejor desempeño en el set de Test? Explique por qué.
3. ¿Bajo que condiciones se puede pensar en sacrificar la precisión por el tiempo de inferencia? De algunos ejemplos claros.
4. ¿Cuál es el impacto en el desempeño de usar el bloque de procesamiento de las imágenes frente a usar las imágenes RAW? (repetir los pasos y observar el cambio en las métricas de desempeño)
5. ¿Basado en la gráfica de generación de características de la etapa de preprocesamiento, hay un palo que dé la impresión de ser más fácil de clasificar? ¿A qué se debe esto? Explique.
6. ¿Cuál fue el palo más difícil de clasificar y a que se puede deber este comportamiento?
7. ¿Qué sucede si se prueba clasificar una carta diferente a un As? Haga varias pruebas y concluya sus resultados.